Çiçek Türlerinin Görüntü Sınıflandırması için Klasik Makine Öğrenmesi ve Derin Öğrenme Modellerinin Karşılaştırılması

Taha Doğukan Bahadır
Yapay Zeka Mühendisliği Bölümü
OSTİM Teknik Üniversitesi
IYU328 – Yapay Zeka Projesi
E-posta: tahatdb19@gmail.com

***Abstract*—Bu çalışmada, beş farklı çiçek türünü (papatya, karahindiba, gül, ayçiçeği, lale) içeren açık kaynaklı bir görüntü veri kümesi üzerinde görüntü sınıflandırma problemi ele alınmıştır. Problem, klasik makine öğrenmesi tabanlı bir model (Lineer Destek Vektör Makinesi – SVM), sıfırdan tasarlanmış bir Evrişimli Sinir Ağı (CNN) ve transfer öğrenme tabanlı bir MobileNetV2 modeli olmak üzere üç farklı yaklaşımla çözülmüştür. Veri kümesi sızıntı (data leakage) oluşturmayacak şekilde %70 eğitim, %15 doğrulama ve %15 test olarak ayrılmıştır. Modeller doğruluk, kesinlik (precision), duyarlılık (recall) ve makro F1-skoru metrikleriyle karşılaştırılmıştır. Sonuçlar, transfer öğrenme tabanlı MobileNetV2 modelinin %86.1 test doğruluğu ile en başarılı model olduğunu, sıfırdan eğitilen CNN modelinin %69.0, klasik SVM modelinin ise %40.2 doğruluk elde ettiğini göstermiştir. Ayrıca hata analizi ve Grad-CAM tabanlı açıklanabilirlik (XAI) analizi gerçekleştirilerek modelin karar mekanizması yorumlanmıştır.**

***Index Terms*—görüntü sınıflandırma, evrişimli sinir ağları, transfer öğrenme, MobileNetV2, destek vektör makinesi, Grad-CAM, açıklanabilir yapay zeka**

I. Giriş ve Problem Tanımı

Görüntü sınıflandırma, yapay zeka ve bilgisayarlı görü alanlarının en temel problemlerinden biridir ve tarım, botanik kataloglama, mobil bitki tanıma uygulamaları gibi pek çok gerçek dünya senaryosunda doğrudan kullanım alanı bulmaktadır. Bu projede ele alınan problem, bir çiçek fotoğrafının hangi türe (papatya, karahindiba, gül, ayçiçeği veya lale) ait olduğunun otomatik olarak belirlenmesidir. Bu problemin motivasyonu, bitki türü tanıma sistemlerinin tarımsal izleme, biyoçeşitlilik kataloglama ve eğitim amaçlı mobil uygulamalarda kullanılabilir olmasıdır. Proje kapsamında, biri klasik makine öğrenmesi, ikisi derin öğrenme tabanlı olmak üzere toplam üç farklı model aynı veri kümesi üzerinde eğitilmiş ve karşılaştırılmıştır.

II. Veri Kümesi

Çalışmada kullanılan veri kümesi, Google'ın resmi TensorFlow örnek veri sunucusundan açık kaynaklı olarak temin edilen *flower_photos* veri kümesidir. Veri kümesi toplam 5 sınıftan oluşmaktadır: *daisy* (papatya), *dandelion* (karahindiba), *roses* (gül), *sunflowers* (ayçiçeği) ve *tulips* (lale). Veri kümesindeki toplam görüntü sayısı 3670'tir.

Veri sızıntısını önlemek amacıyla, her sınıf için görüntüler önce rastgele (sabit *seed=42* ile) karıştırılmış, ardından %70 eğitim, %15 doğrulama ve %15 test olacak şekilde ayrılmıştır. Bu işlem her sınıf için ayrı ayrı uygulanarak sınıf dağılımının dengeli kalması sağlanmıştır. Elde edilen bölünme Tablo I içerisinde özetlenmiştir.

TABLE I
Eğitim, doğrulama ve test kümesi görüntü sayıları

Küme	Görüntü Sayısı	Oran	Sınıf Sayısı
Eğitim (Train)	2567	%70	5
Doğrulama (Val)	551	%15	5
Test	552	%15	5
Toplam	**3670**	%100	5

III. Veri Ön İşleme

Tüm görüntüler 128×128 piksel boyutuna yeniden ölçeklendirilmiş ve $[0, 1]$ aralığına normalize edilmiştir (`rescale=1./255`). Eğitim kümesinde modelin genelleme kapasitesini artırmak amacıyla veri artırma (*data augmentation*) teknikleri uygulanmıştır: $\pm 20^\circ$ döndürme, %20 genişlik/yükseklik kayması ve yatay çevirme (*horizontal flip*). Doğrulama ve test kümelerine ise herhangi bir artırma işlemi uygulanmamış, sadece normalizasyon yapılmıştır; bu sayede modelin gerçek performansını etkileyebilecek veri sızıntısının önüne geçilmiştir. Klasik SVM modeli için ise her görüntü $128 \times 128 \times 3 = 49152$ boyutlu bir öznitelik vektörüne düzleştirilmiştir (*flatten*).

IV. Kullanılan Modeller

Proje kapsamında biri klasik makine öğrenmesi, ikisi derin öğrenme tabanlı olmak üzere üç model geliştirilmiştir.

A. Model 1: Lineer Destek Vektör Makinesi (SVM)

Klasik makine öğrenmesi modeli olarak, düzleştirilmiş piksel vektörleri üzerinde çalışan bir `LinearSVC` modeli (`dual=False`, `max_iter=1000`) kullanılmıştır. Bu model, ham piksel değerlerinin doğrusal olarak ayrıştırılabilirliğini test etmek amacıyla temel bir karşılaştırma (*baseline*) noktası oluşturmaktadır.

B. Model 2: Sıfırdan Eğitilmiş Evrişimli Sinir Ağı (CNN)

İkinci model, sıfırdan tasarlanmış bir CNN mimarisidir. Mimari iki evrişim bloğu (32 ve 64 filtreli 3×3 Conv2D katmanları, her birinin ardından 2×2 MaxPooling), bir düzleştirme katmanı, 64 nöronlu tam bağlı bir gizli katman ve 5 sınıflı *softmax* çıkış katmanından oluşmaktadır. Model `adam` optimize edici ve `categorical_crossentropy` kayıp fonksiyonu ile 20 epoch boyunca eğitilmiştir.

C. Model 3: MobileNetV2 ile Transfer Öğrenme

Üçüncü model, ImageNet üzerinde önceden eğitilmiş MobileNetV2 mimarisinin dondurulmuş (`trainable=False`) taban katmanları üzerine *GlobalAveragePooling2D*, 64 nöronlu yoğun katman ve 5 sınıflı *softmax* çıkış katmanı eklenerek oluşturulmuştur. Bu model, önceden öğrenilmiş genel görsel özniteliklerden faydalanarak daha az veriyle daha yüksek performans elde etmeyi hedeflemektedir. Model de 20 epoch boyunca eğitilmiştir.

V. Deney Tasarımı

Üç model de aynı eğitim/doğrulama/test bölünmesi üzerinde, aynı görüntü boyutu (128×128) ve aynı *batch size* (32) ile eğitilmiş ve test edilmiştir. Derin öğrenme modelleri 20 epoch boyunca `adam` optimize edici ile eğitilmiş, performans karşılaştırması doğruluk (*accuracy*), makro kesinlik (*precision*), makro duyarlılık (*recall*) ve makro F1-skoru metrikleri üzerinden yapılmıştır. Bu sayede sınıflar arası dengesizlikten bağımsız, adil bir karşılaştırma sağlanmıştır.

VI. Sonuçlar ve Performans Metrikleri

A. Öğrenme Eğrileri

Şekil 1 ve Şekil 2, sırasıyla sıfırdan eğitilen CNN ve MobileNetV2 modellerinin eğitim süreci boyunca doğruluk ve kayıp değerlerinin değişimini göstermektedir. MobileNetV2 modelinin çok daha hızlı yakınsadığı ve daha düşük kayıp değerlerine ulaştığı görülmektedir.

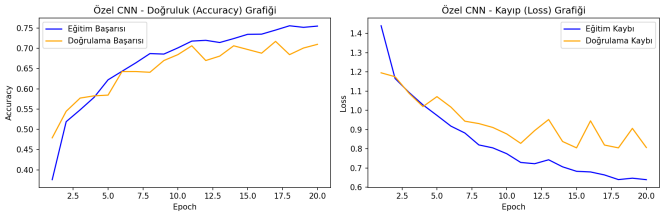


Fig. 1. Sıfırdan eğitilen CNN modelinin eğitim/doğrulama doğruluk ve kayıp grafikleri.

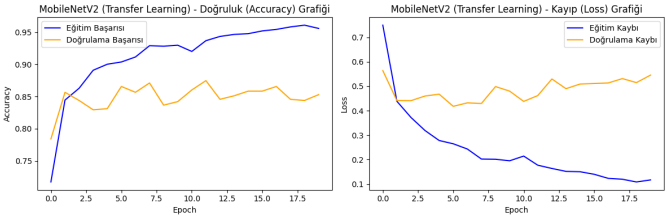


Fig. 2. MobileNetV2 (Transfer Öğrenme) modelinin eğitim/doğrulama doğruluk ve kayıp grafikleri.

B. Model Karşılaştırma Tablosu

Tablo II, üç modelin test kümesi üzerindeki performans metriklerini karşılaştırmaktadır.

TABLE II
ÜÇ MODELIN TEST KÜMESI PERFORMANS KARŞILAŞTIRMASI

Model	Acc.	Prec.	Recall	F1
SVM (Klasik ML)	%40.2	0.412	0.387	0.387
Özel CNN	%69.0	0.722	0.678	0.674
MobileNetV2 (TL)	**%86.1**	**0.864**	**0.854**	**0.856**

C. Karmaşıklık Matriksleri (Confusion Matrix)

Şekil 3 ve Şekil 4, sırasıyla özel CNN ve MobileNetV2 modellerinin test kümesi üzerindeki karmaşıklık matrislerini göstermektedir.

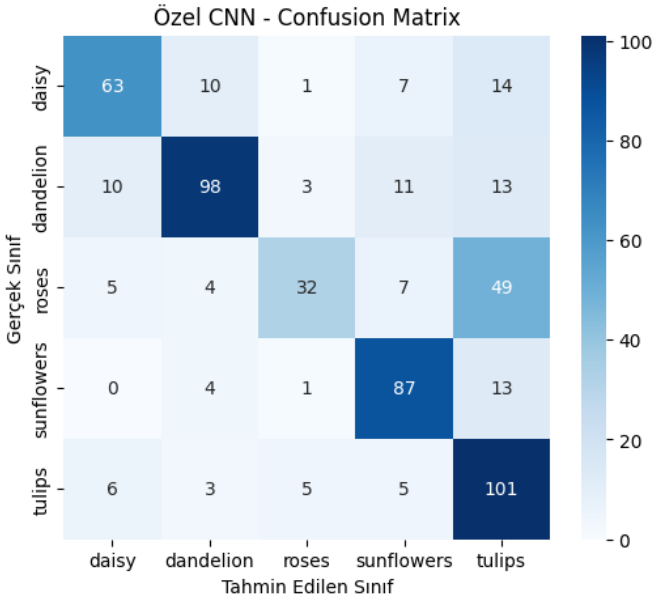


Fig. 3. Özel CNN modeli karmaşıklık matriksi.

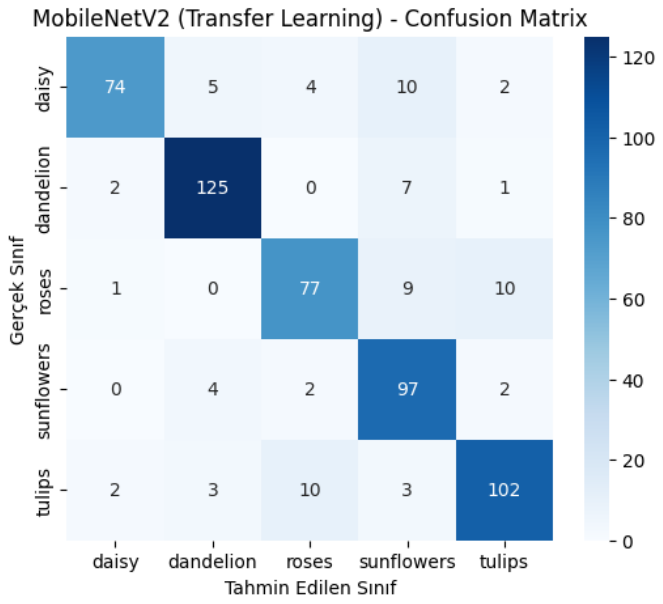


Fig. 4. MobileNetV2 (Transfer Öğrenme) modeli karmaşıklık matriksi.

En başarılı model olan MobileNetV2'nin karmaşıklık matriksi, sınıflar arası karışıklığın oldukça az olduğunu ve özellikle *dandelion* sınıfının (125/135 doğru) çok başarılı bir şekilde ayırt edildiğini göstermektedir (Şekil 5).

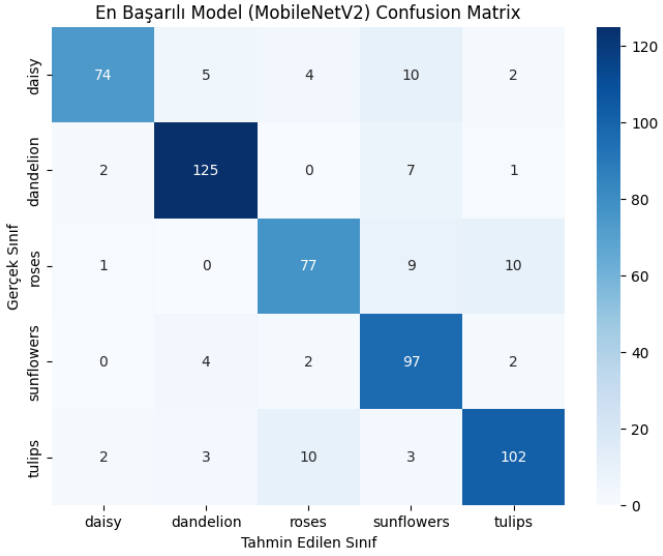


Fig. 5. En başarılı model (MobileNetV2) için detaylı karmaşıklık matriksi.

VII. Hata Analizi

MobileNetV2 modeli, 552 test görüntüsünden 77'sini hatalı sınıflandırmıştır (%14 hata oranı). En çok karışıklığın *roses* (gül) sınıfı ile *tulips* (lale) sınıfı arasında olduğu gözlemlenmiştir; bunun nedeni, her iki çiçeğin de bazı açılardan benzer renk tonu ve yaprak şekline sahip olmasıdır. Şekil 6 ve Şekil 7, modelin yanlış sınıflandırdığı örnek görüntüleri sergilemektedir.

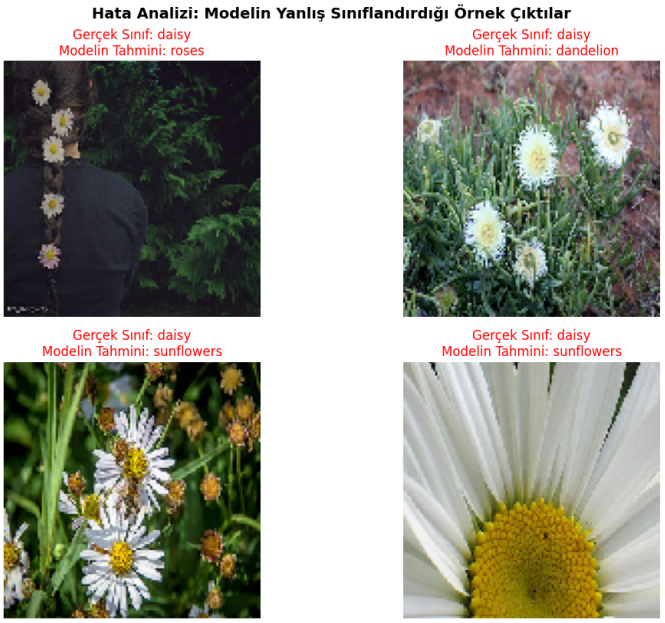


Fig. 6. MobileNetV2 modelinin yanlış sınıflandırdığı 4 örnek test görüntüsü (gerçek ve tahmin edilen sınıflarla).



Fig. 7. Modelin en çok zorlandığı 3 örnek görüntü üzerinden hata analizi.

Hata analizi sonucunda, modelin özellikle çiçeğin merkezi net görünmediğinde, görüntü bulanık olduğunda veya arka planda benzer renkte bitki örtüsü bulunduğunda hata yaptığı görülmüştür. Bu durum, modelin global renk/doku özniteliklerine fazla bağımlı kaldığını, ince taneli (*fine-grained*) ayrımlarda zorlandığını göstermektedir.

VIII. Açıklanabilirlik (XAI) Analizi

Modelin karar mekanizmasını yorumlamak amacıyla MobileNetV2 modeli üzerinde Grad-CAM (*Gradient-weighted Class Activation Mapping*) tekniği uygulanmıştır. Grad-CAM, modelin sınıflandırma kararını verirken görüntünün hangi bölgelerine daha fazla ağırlık verdiğini ısı haritası (*heatmap*) şeklinde görselleştirmektedir. Şekil 8, örnek bir test görüntüsü üzerinde elde edilen Grad-CAM çıktısını göstermektedir.

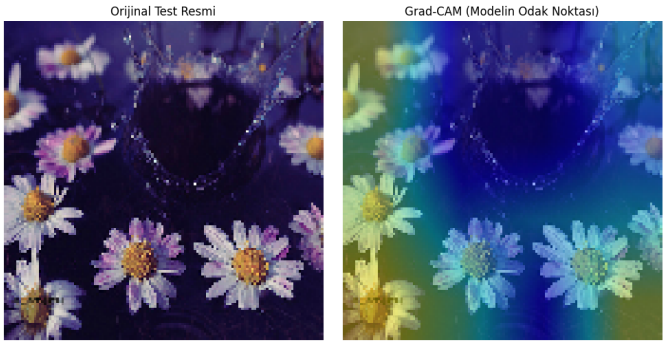


Fig. 8. Örnek bir test görüntüsü için orijinal görüntü (solda) ve Grad-CAM ısı haritası (sağda). Kırmızı/sıcak bölgeler modelin kararında en etkili olan piksel bölgelerini temsil etmektedir.

Görselden de anlaşılacağı üzere, model kararını verirken görüntünün arka planından ziyade ağırlıklı olarak çiçeğin yaprak ve taç yaprak (*petal*) bölgelerine odaklanmaktadır. Bu durum, modelin anlamlı ve insan mantığıyla örtüşen görsel özniteliklere dayanarak karar verdiğini, yani modelin yalnızca arka plan bilgisini ezberlemediğini doğrulamaktadır.

IX. Bulguların Yorumlanması

Elde edilen sonuçlar, derin öğrenme tabanlı yaklaşımların ham piksel verisi üzerinde çalışan klasik makine öğrenmesi modeline kıyasla bu görüntü sınıflandırma probleminde belirgin şekilde daha başarılı olduğunu göstermektedir. SVM modelinin düşük performansının (%40.2) temel nedeni, düzleştirilmiş piksel vektörlerinin uzaysal (*spatial*) bilgiyi tamamen kaybetmesi ve doğrusal bir karar sınırının görüntü verisindeki karmaşık örüntüleri yakalayamamasıdır. Sıfırdan eğitilen CNN modeli (%69.0), evrişim katmanları sayesinde uzaysal örüntüleri öğrenebilmiş, fakat sınırlı veri miktarı nedeniyle aşırı öğrenmeye (*overfitting*) eğilim göstermiştir. MobileNetV2 transfer öğrenme modeli (%86.1) ise, ImageNet üzerinde önceden öğrenilmiş genel görsel özniteliklerden faydalanarak sınırlı veriyle bile en yüksek ve en kararlı performansı elde etmiştir.

X. Limitasyonlar ve Gelecek Çalışma Önerileri

Bu çalışmanın bazı kısıtları bulunmaktadır: (1) veri kümesi boyutu (3670 görüntü) derin öğrenme modelleri için nispeten sınırlıdır; (2) görüntüler 128×128 gibi düşük bir çözünürlüğe indirgenmiştir, bu da ince detayların kaybına yol açabilmektedir; (3) MobileNetV2 modelinde sadece son katmanlar eğitilmiş, ince ayar (*fine-tuning*) uygulanmamıştır. Gelecek çalışmalarda, MobileNetV2'nin üst katmanlarına ince ayar yapılması, daha yüksek çözünürlüklü görüntülerle eğitim, EfficientNet veya Vision Transformer (ViT) gibi daha güncel mimarilerin denenmesi ve veri kümesinin genişletilmesi önerilmektedir.

XI. Sonuç

Bu projede, çiçek türü sınıflandırma problemi üç farklı model (SVM, sıfırdan CNN, MobileNetV2 transfer öğrenme) ile ele alınmış, modeller aynı veri ve aynı metrikler üzerinden karşılaştırılmıştır. MobileNetV2 transfer öğrenme modeli %86.1 doğruluk ile en başarılı sonucu vermiştir. Hata analizi ve Grad-CAM tabanlı açıklanabilirlik analizi, modelin anlamlı görsel özniteliklere dayandığını ve temel hata kaynaklarının görsel benzerlik içeren sınıflar (gül–lale) arasında yoğunlaştığını ortaya koymuştur.

References

[1] TensorFlow, "TF Flowers Dataset," Google Inc., https://storage.googleapis.com/download.tensorflow.org/example_images/flower_photos.tgz, 2019.

[2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proc. IEEE CVPR*, 2018, pp. 4510–4520.

[3] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," in *Proc. IEEE ICCV*, 2017, pp. 618–626.

[4] C. Cortes, V. Vapnik, "Support-Vector Networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.

[5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.